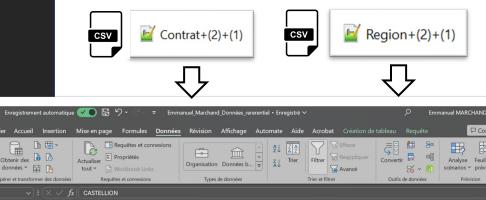


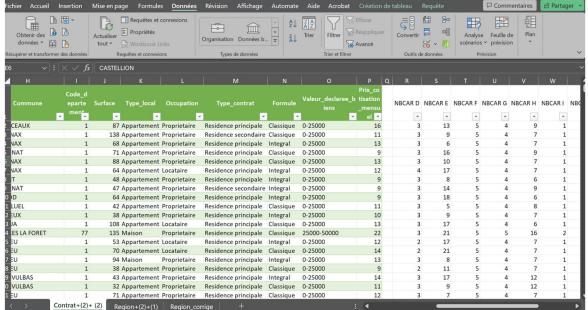




Etape 01 : dictionnaire de données 1/3

Méthode de manipulation des données





J'ai importé les deux fichiers CSV dans un seul fichier Excel avec un onglet par fichier CSV. Cela m'a permis de faire mon analyse grâce à des filtres, des fonctions et des mises en forme conditionnelles.

Une fois le dictionnaire de données défini et les données corrigées, j'ai exporté chaque feuille Excel dans un fichier CSV. J'ai ensuite ouvert chacun des fichiers CSV avec l'outil Notepad++ afin de les convertir en UTF8. Les fichiers étaient ainsi prêts à être chargés dans la base de données.



Etape 01 : dictionnaire de données 2/3

Méthode d'analyse des données

Il est établi que chacun des fichiers CSV sera une table. Il est donc nécessaire d'utiliser les entêtes de fichiers CVS pour déterminer la liste des colonnes qu'il faudra créer dans chacune des tables.

Afin de garantir le minimum de maintenance sur la base de données, j'ai appliqué une marge de sécurité sur l'ensemble des longueurs d'attributs., je n'ai donc pas attribué strictement la longueur maximale de chaque attribut.

Pour déterminer la longueur maximum de chacun des attributs, j'ai utilisé la fonction Excel NBCAR, et j'ai ensuite trié par ordre décroissant.

Pour chacun des attributs j'ai utilisé les filtres d'Excel pour vérifier s'il y avait des valeurs vides dans la liste de donnée.

Pour déterminer la typologie de données, pour chaque attribut numérique, j'ai fait un filtre en recherchant des lettres, si la recherche ne retournait rien alors j'ai considéré le champ comme entier. Il n'y avait aucun attribut avec des virgules, donc les type FLOAT ou DECIMAL, n'ont pas été utilisés.

Méthode de correction des données

J'ai utilisé les mises en forme conditionnelle pour détecter les doublons de données par attributs et ainsi déterminé la nécessité de clé étrangère. Dans la table Contrat, j'ai changé le nom de l'attribut 'Code_dep_code_commune' par 'Lien_contrat_region' pour mettre en évidence la clé étrangère en relation 0 à PLUSIEURS entre Région et Contrat.

J'ai corrigé les valeurs de l'attribut 'Code_dep_code_commune' de la table Région, car tous les départements commençant par zéro n'avaient pas de zéro en première position de cet attribut. J'ai utilisé la fonction Excel CONCATENER pour l'ajouter. Sans cette modification, le lien entre les tables Contrat et Région aurait été perdu pour tous les départements commençant par un zéro.



Etape 01 : dictionnaire de données 3/3



J'ai consulté le site de data.gouv.fr pour trouver la documentation du fichier d'interface que j'ai téléchargé. Cela m'a permis identifier le contenu de chacun des attributs du fichier Région



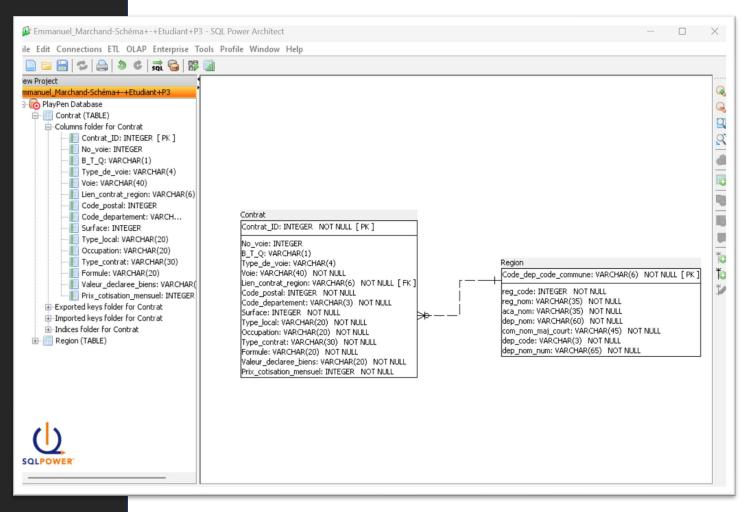
	N	*	T-20-	CI.	Combania	Description .
	Nom des colonnes	Type de donnée:	Taille	Clé	Contrainte	Description
	Contrat_ID	INT		Clé primaire	NOT NULL	Id unique pour les contrats
	No_voie	INT				Numéro dans la voie pour l'adresse du logement assuré
	B_T_Q	CHAR	1			Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
	Type_de_voie	VARCHAR	4			Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route),
	Voie	VARCHAR	40		NOT NULL	Libellé de la voie pour l'adresse du logement assuré
	Lien_contrat_region	VARCHAR	6	Clé secondaire	NOT NULL	Lien pour la relation PLUSIEURS entre CONTRAT et REGION
S	Code_postal	INT			NOT NULL	Code postal pour l'adresse du logement assuré
AT.	Commune	VARCHAR	45		NOT NULL	Libellé de la commune de l'adresse du logement
CONTRAT.CSV	Code_departement	INT			NOT NULL	Code département pour l'adresse du logement assuré
ξ	Surface	INT			NOT NULL	Surface du logement assuré
_	Type_local	VARCHAR	20		NOT NULL	Type de logement : Appartement ou Maison
	Occupation	VARCHAR	20		NOT NULL	Le statut de l'occupant : Propriétaire ou Locataire
	Type_contrat	VARCHAR	30		NOT NULL	Le type de contrat d'assurance : Mise en location, Résidence principale, résidence secondaire
	Formule	VARCHAR	20		NOT NULL	La formule souscrite par le client : Classique, Intégral.
	Valeur_declaree_biens	VARCHAR	20		NOT NULL	Une fourchette de la valeur des biens déclarés dans le logement.
	Prix_cotisation_mensuel	INT			NOT NULL	Le prix mensuel de la cotisation client.
Î	Code_dep_code_commune	VARCHAR	6	Clé primaire	NOT NULL	Concaténation du code département et code commune pour avoir une clé unique
	reg_code	INT			NOT NULL	Code région
CSV	reg_nom	VARCHAR	35		NOT NULL	Libellé région
zi I	aca_nom	VARCHAR	35		NOT NULL	Libellé de l'académie
REGIOI	dep_nom	VARCHAR	60		NOT NULL	Libellé du département
Ä	com_nom_maj_court	VARCHAR	45		NOT NULL	Libellé court de la commune en majuscule
	dep_code	VARCHAR	3		NOT NULL	Code département
	dep nom num	VARCHAR	65		NOT NULL	Code et libellé du département

CONCLUSION: L'observation du contenu de chacun des attributs présents dans les fichiers CSV, m'a permis de :

- Déterminer les longueurs de champs
- Déterminer si l'attribut accepte les valeurs NULL
- Déterminer les typologies de données
- Corriger les erreurs de données.



Etape 02 : créer le schéma relationnel normalisé en 3NF



- J'ai suivi **les recommandations OpenClassroom** de l'étape 02 à savoir :
 - J'ai téléchargé et installé le logiciel SQL Power Architect. Pour me familiariser avec celui-ci j'ai regardé les liens fournis pointant vers des vidéos tutoriels.
 - J'ai suivi la partie du cours pour la normalisation 3NF.

- (2) Le respect de la normalisation **3NF** implique :
 - Que chaque table soit constituée d'une clé primaire
 - La suppression des redondances de données. Pour cela j'ai supprimé l'attribut 'Commune' de la table Contrat, car cette information se trouvent déjà dans la table de référence Région, dans l'attribut 'com nom maj court'.

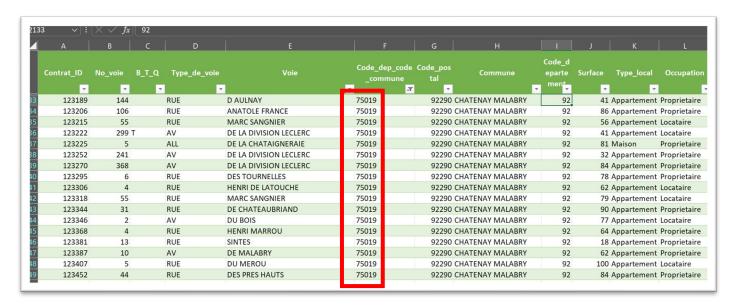


Etape 02: point d'attention sur la forme normale 3NF



ATTENTION

J'ai conservé les colonnes 'Code departement' et 'dep_code' respectivement dans les tables **Contrat** et **Région** alors qu'elles étaient redondantes. Pourquoi ? : il y a des incohérences de données dans ces tables et le nettoyage des données ne fait pas l'objet de cet exercice. En effet dans la table **Contrat** , il y a des attributs 'Code_departement' qui sont erronés, par exemple la ville de CHATENAY MALABRY est notée dans le 75 en lui attachant le Code_dep_code_commune ' égal à 75019 et alors qu'elle devrait être dans le 92 avec le code_dep_code_commune égal à 92019. Cela ne permet donc pas de faire des INNER JOIN fiables entre les deux tables.



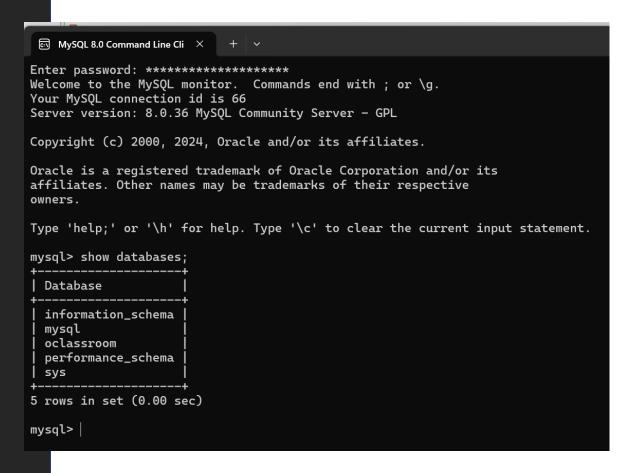
Il faut également noter que dans la table 'Region' on retrouve toujours cette même ville présente dans deux départements différents.



Code_dep_code	reg_co	reg_nom	aca_no	dep_nom	com_nom_maj_court		dep_code	dep_nom_num	
_commune	ge -		m N			AT .	~		~
5019	11 Ile-0	le-France	Paris	Paris	CHATENAY MALABRY	7!	5	Paris (75)	
2019	11 lle-c	le-France	Versaille	e: Hauts-de-Sei	n CHATENAY MALABRY	92	2	Hauts-de-Seine (92)	



Etape 03 : créer et charger la base de données 1/4



J'ai suivi **les recommandations OpenClassroom** de l'étape 03 à savoir :

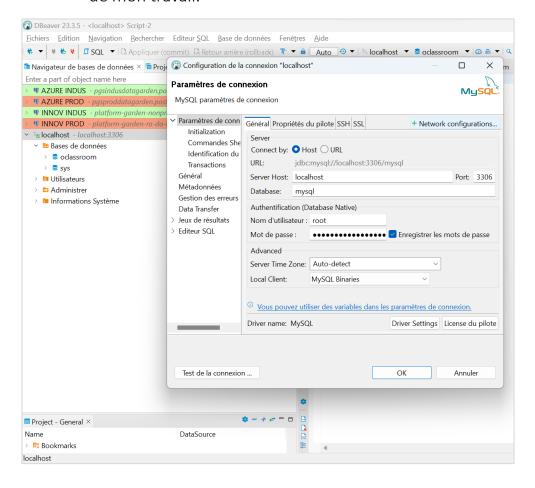
- J'ai choisi le SGBD MySQL parmi ceux proposés. C'est celui avec lequel j'ai déjà travaillé.
- J'ai installé MySQL sur mon PC pour créer une base en local.
- Dans MysSQL avec la commande CREATE DATABASE [IF NOT EXISTS] oclassroom; , j'ai créé une base dédiée aux projets OpenClassroom pour ne pas travailler directement sur la base Système SYS



Etape 03 : créer et charger la base de données 2/4

J'ai créé une connexion de base depuis le logiciel

Dbeaver qui est le logiciel de gestion de base de données que j'utilise actuellement dans le cadre de mon travail.



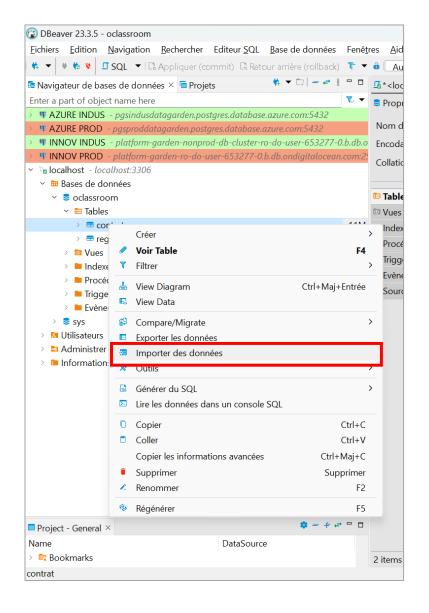
J'ai exécuté le script SQL de création de base issue du logiciel de modélisation de base SQL Power Architecte.

```
■ oclassroom  

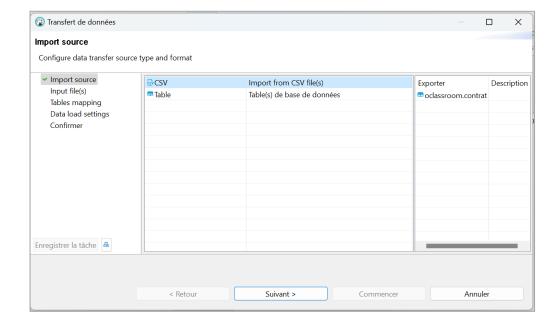
■*<localhost> Script-3 ×
    CREATE TABLE Region
                    Code_dep_code_commune VARCHAR(6) NOT NULL,
                    reg code INT NOT NULL,
                    reg nom VARCHAR (35) NOT NULL,
                    aca nom VARCHAR (35) NOT NULL,
                    dep nom VARCHAR (60) NOT NULL,
                    com nom maj court VARCHAR (45) NOT NULL,
                    dep code VARCHAR (3) NOT NULL,
                    dep nom num VARCHAR (65) NOT NULL,
                    PRIMARY KEY (Code dep code commune)
   CREATE TABLE Contrat (
                    Contrat ID INT NOT NULL,
                    No voie INT,
                    B T O VARCHAR (1),
                    Type de voie VARCHAR(4),
                     Voie VARCHAR (40) NOT NULL,
                    Lien contrat region VARCHAR(6) NOT NULL,
                    Code postal INT NOT NULL,
                    Code departement VARCHAR(3) NOT NULL,
                    Surface INT NOT NULL,
                     Type local VARCHAR(20) NOT NULL,
                    Occupation VARCHAR(20) NOT NULL,
                    Type contrat VARCHAR (30) NOT NULL,
                    Formule VARCHAR (20) NOT NULL,
                    Valeur declaree biens VARCHAR(20) NOT NULL,
                    Prix cotisation mensuel INT NOT NULL,
                    PRIMARY KEY (Contrat ID)
    ALTER TABLE Contrat MODIFY COLUMN Lien contrat region VARCHAR(6) COMMENT 'Clé étrangère pour la relation PLUSIEU
    ALTER TABLE Contrat ADD CONSTRAINT region contrat fk
    FOREIGN KEY (Lien contrat region)
    REFERENCES Region (Code dep code commune)
    ON DELETE NO ACTION
    ON UPDATE NO ACTION;
CET fr Inscriptible
                        Insertion avancée
                                         41:21:1552
                                                            Sel: 0 | 0
```



Etape 03 : créer et charger la base de données 3/4



J'ai ensuite utilisé l'utilitaire d'importation de données de Dbeaver pour charger chacun des fichiers CSV, créés à l'étape 01, dans chacune des tables.



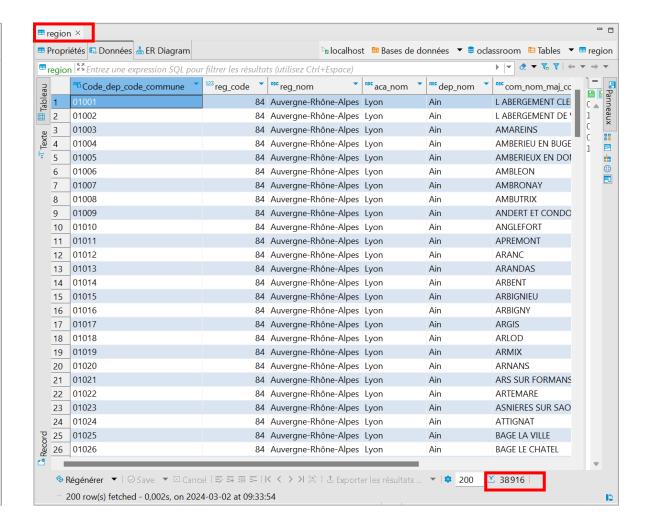
Page 9



Etape 03 : créer et charger la base de données 4/4

Une fois les données chargées, on obtient bien le nombre de lignes attendues dans chacune des tables.

⊞ c	ontra	t ×									
⊞ P	roprie	étés 🖪 Données 🌡	ER Diagram		2	b lo	calhost 🙃 Bases de données	▼ 🛢 oclassroom 🗀 🤊	lables	▼ 🖪	contrat
= c	ontra	t Entrez une exp	ression SQL pou	r filtrer les rési	ultats (utilisez Ctrl	+Es	pace)	▶ ▼	V V	← :	▼ → ▼
⊞ Tableau		¹²⁸ Contrat_ID ▼	¹²³ No_voie ▼	^{ABC} B_T_Q ▼	Type_de_voie	•	ABC Voie	**Lien_contrat_region	▼ 123	Cc _	Pa Pa
able	1	100 601	190	Α	RUE		CENTRALE	№ 01350			Panneaux
ii	2	100602	347		RUE		DU CHATEAU	₫ 01103			eaux
2	3	100 603	58		AV		DU MONT BLANC	☑ 01143			000
oT Texte	4	100604	140		RUE		DE L'ABBE JOLIVET	№ 01288			⊗ ⊕
Ĥ	5	100 605	39		RUE		BUFFON	№ 01033			<u>™</u>
	6	100 606	8		RUE		DE GENEVE	☑ 01354			⊕
	7	100607	2		RUE		DU RECULET	☑ 01354			
	8	100608	1403		RUE		JEAN DE GINGINS	☑ 01143			
	9	100 609	226		ALL		DES CAPUCINES	☑ 01354			
	10	100610	276		RTE		DE POUGNY	₫ 01288			
	11	100611	79		CRS		DE VERDUN	☑ 01283			
	12	100612	240		RUE		DE PRE BAILLY	№ 01173			
	13	100613	3		RUE		TURENNE	№ 01033			
	14	100614	44		ALL		DU SQUARE DE LAUSANNE	☑ 01143			
	15	100615	59		RUE		ALEXANDRE BERARD	№ 01004			
	16	100616	282		CHE		DES LONGES RAYES	№ 01071			
	17	100617	54		GR		GRANDE RUE	₫ 01396			
	18	100618	1		RUE		DE GEX	№ 01160			
	19	100619	17		LOT		LES JARDINS DE CHEVRY	№ 01103			
	20	100620	329		RUE		DES CARPIERES	₫ 01399			
	21	100 621	369		AV		CHARLES DE GAULLE	₫ 01202			
	22	100622	6		RUE		DES USINIERS	№ 01173			
	23	100 623	2		RUE		DU JURA	№ 01354			
	24	100624	54		RUE		MARCEL DEMIA	№ 01004			
ord	25	100 625	269		CHE		DE CHARIGNIN	☑ 01034			
L	26	100626	322		RUE		DE BRETIGNY	☑ 01281			
ď						ı	Exporter les résultats 🔻 🔡	200 🖺 30335]		86
	2	00 row(s) fetched -	0,001s, on 2022	1-03-02 at 09:	30:07						12





Etape 04 et 05 : créer les requêtes SQL



Une fois ma Base créée, et mes tables chargées , j'ai exécuté chacune des requêtes dans l'éditeur SQL de Dbeaver. Le détail se trouve en annexe.

- select contrat_ID, Surface from contrat c
 where Commune = 'Caen'
- select contrat_ID, Type_contrat, Formule from contrat

 c
 where Type_local ='Maison'
 and Code_departement = 71
 order by Formule
- select distinct reg_nom
 from region r
- select count(*) from contrat c
 where Type_contrat = 'Residence principale'
- select AVG(Surface) from contrat c
 where Code_departement = 75
- SELECT contrat_id, Surface
 FROM contrat c
 ORDER BY surface DESC
 LIMIT 5
- 07 select AVG(Prix_cotisation_mensuel) from contrat c

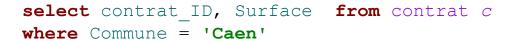
- select Valeur_declaree_biens , count(*) as nb_contrats
 from contrat c
 group by Valeur_declaree_biens
 order by 2 desc
- select Code_departement , AVG(Prix_cotisation_mensuel)
 from contrat c
 group by Code_departement
 order by AVG(Prix_cotisation_mensuel) desc
 limit 10
- select count(*) as nb_contrats
 from contrat c , region r
 where Lien_contrat_region = r.Code_dep_code_commune
 and c.Formule = 'Integral'
 and r.reg_nom = 'Pays de la Loire'
- select r.com_nom_maj_court
 from contrat c , region r
 where Lien_contrat_region = r.Code_dep_code_commune
 group by 1
 having count(*) >= 150
- select r.reg_nom , count(c.Contrat_ID) as
 Nb_contrat_total
 from contrat c , region r
 where Lien_contrat_region = r.Code_dep_code_commune
 group by 1
 Order by 2 desc



ANNEXES



Requête O1 : Lister les numéros de contrats (contrat_ID) avec leur surface pour la commune de Caen.



			l l	
an		¹² 6 contrat_ID ▼	¹²³ Surface	
Tableau	1	103791	35	
	2	103792	99	
e,	3	103793	40	
Texte	4	103794	20	
Ê				



Requête 02 : Lister les numéros de contrats avec le type de contrat et leur formule pour les maisons du département 71.

```
select contrat_ID, Type_contrat, Formule from contrat c
where Type_local ='Maison'
and Code_departement = 71
order by Formule
```

lean		¹⅔ contrat_ID ▼	Type_contrat	Formule •
able	1	114779	Residence principale	Classique
	2	114782	Residence principale	Classique
e	3	114768	Residence principale	Integral
Texte	4	114812	Residence principale	Integral



Requête 03 : Lister le nom des régions de France.

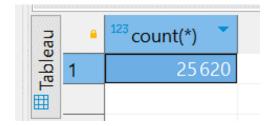
 $\begin{array}{c} \textbf{select distinct} \ \text{reg_nom} \\ \textbf{from} \ \text{region} \ r \end{array}$

san		reg_nom •
Tableau	1	Auvergne-Rhône-Alpes
	2	Hauts-de-France
e,	3	Provence-Alpes-Côte d'Azur
[∙] T Texte	4	Grand Est
Ê	5	Occitanie
	6	Normandie
	7	Nouvelle-Aquitaine
	8	Centre-Val de Loire
	9	Bourgogne-Franche-Comté
	10	Bretagne
	11	Corse
	12	Pays de la Loire
	13	lle-de-France
	14	Guadeloupe
	15	Martinique
	16	Guyane
	17	La Réunion
ō	18	Collectivités d'outre-mer
ecord	19	Mayotte
~		



Requête 04 : Combien existe-t-il de contrats sur les résidences principales ?

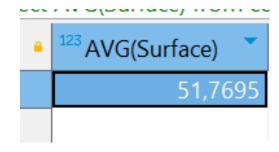
```
select count(*) from contrat c
where Type_contrat = 'Residence principale'
```





Requête 05 : Quelle est la surface moyenne des logements avec un contrat à Paris ?

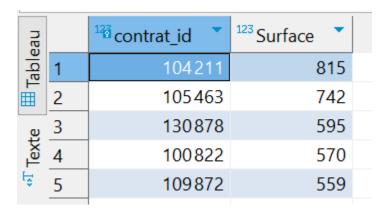
```
select AVG(Surface) from contrat c
where Code_departement = 75
```





Requête 06 : Quels sont les 5 contrats qui ont les surfaces les plus élevées ?

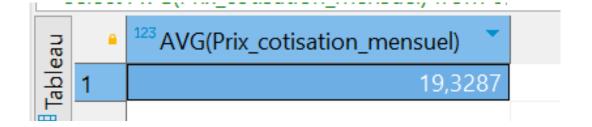
```
SELECT contrat_id, Surface
  FROM contrat c
ORDER BY surface DESC
LIMIT 5
```





Requête 07 : Quel est le prix moyen de la cotisation mensuelle ?

select AVG(Prix cotisation mensuel) **from** contrat c





Requête 08 : Quel est le nombre de contrats pour chaque catégorie de prix de la valeur déclarée des biens ?

```
select Valeur_declaree_biens , count(*) as nb_contrats
from contrat c
group by 1
order by 2 desc
```

an		Valeur_declaree_biens	¹²³ nb_contrats ▼
Tableau	1	0-25000	22720
	2	25000-50000	6815
e,	3	50000-100000	696
Text	4	100000+	104
H			



Requête 09 : Quel est le classement des 10 départements où le prix moyen de la cotisation est le plus élevé ?

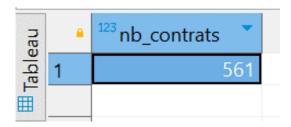
```
select Code_departement , AVG(Prix_cotisation_mensuel)
from contrat c
group by Code_departement
order by AVG(Prix_cotisation_mensuel) desc
limit 10
```

•
91
94
42
02
68
89
76
73
84
83
5 3 1



Requête 10 : Quel est le nombre de contrats avec des formules "Intégral" pour la région Pays de la Loire ?

```
select count(*) as nb_contrats
from contrat c , region r
where Lien_contrat_region = r.Code_dep_code_commune
and c.Formule = 'Integral'
and r.reg_nom = 'Pays de la Loire'
```





Requête 11: Quelle est la liste des communes ayant au moins 150 contrats?

```
select r.com_nom_maj_court, count(*) as nb_contrat
from contrat c, region r
where Lien_contrat_region= r.Code_dep_code_commune
group by 1
having count(*) >= 150
order by 2 desc
```

			-v /
sau		com_nom_maj_court	¹²³ nb_contrat ▼
Tableau	1	PARIS 18	515
	2	PARIS 17	468
, e	3	PARIS 15	407
[⊹] T Texte	4	PARIS 16	394
Ê	5	NICE	387
	6	PARIS 11	381
	7	BORDEAUX	302
	8	PARIS 20	302
	9	NANTES	291
	10	PARIS 19	266
	11	PARIS 10	263
	12	PARIS 12	252
	13	PARIS 14	222
	14	GRENOBLE	220
	15	PARIS 9	204
	16	TOULOUSE	187
	17	TOULON	170
	18	COURBEVOIE	163
ord	19	LILLE	161
Record	20	PARIS 3	159
40			



Requête 12 : Quel est le nombre de contrats pour chaque région ?

select r.reg_nom , count(c.Contrat_ID) as Nb_contrat_total
from contrat c , region r
where Lien_contrat_region = r.Code_dep_code_commune

group by 1

Order by 2 desc

an		reg_nom •	¹²³ Nb_contrat_total
Tableau	1	Ile-de-France	13474
Ш	2	Provence-Alpes-Côte d'Azur	3287
e e	3	Auvergne-Rhône-Alpes	2972
[⊕] Texte	4	Nouvelle-Aquitaine	2097
Ê	5	Occitanie	1837
	6	Hauts-de-France	1327
	7	Pays de la Loire	1138
	8	Bretagne	945
	9	Normandie	898
	10	Grand Est	806
	11	Centre-Val de Loire	804
	12	Bourgogne-Franche-Comté	402
	13	Corse	247
	14	Martinique	60
	15	Guyane	37
	16	La Réunion	4
	16	La Reunion	4